基于自适应非平稳高斯过程回归的股票趋势预测研究

2025.12.24

1 引言

1.1 研究背景：从确定性回归到随机过程

回归分析是一种常见的数据预测工具，传统的线性回归模型 $Y = AX + N$ 或非线性扩展 $Y = f(X) + N$ 本质上差异很小，构建的都是确定的函数对象，缺乏对模型本身随机性的描述。

近年来，高斯过程回归（GPR）因其独特的贝叶斯性质受到关注，尤其是在人工智能和机器学习领域，根据给出的文献中的介绍，GPR 采用 $Y = g(X) + N$ 的形式，其中 $g(X)$ 是高斯过程的样本轨道片段。通俗的讲，普通的回归是画一条确定的线，而高斯过程是画一条带阴影的线，数据越多，阴影越窄（越确定）；离数据越远，阴影越宽（越不确定）。

这种方法不仅能进行点预测，还能通过核函数刻画数据间的相关性，简单来说就是衡量两天的数据有多相似，输出预测的不确定性范围，引入了随机性，刚好适合波动的股票市场。

1.2 任务挑战：平稳性假设与现有研究

本研究的任务是基于纳斯达克的真实股票数据，探索 GPR 在时间序列预测中的能力，并且与国外学生已有的研究做对比，作为作业的基线。

然而，在复现与深入研究中，面临核心挑战在于数据的平稳性，严格的统计推断往往依赖于随机过程是严平稳或至少是宽平稳的，即均值和协方差不随时间变化，但真实的股票市场受多重因素影响，往往表现出非平稳特性，且不同时间段的波动率呈现显著差异，直接沿用文献中的静态核函数配置，在应对市场剧烈变化时可能存在适应性不足的问题。

Fig. 1: Analysis of Non-stationarity and Regime Shift in NDX Price Series

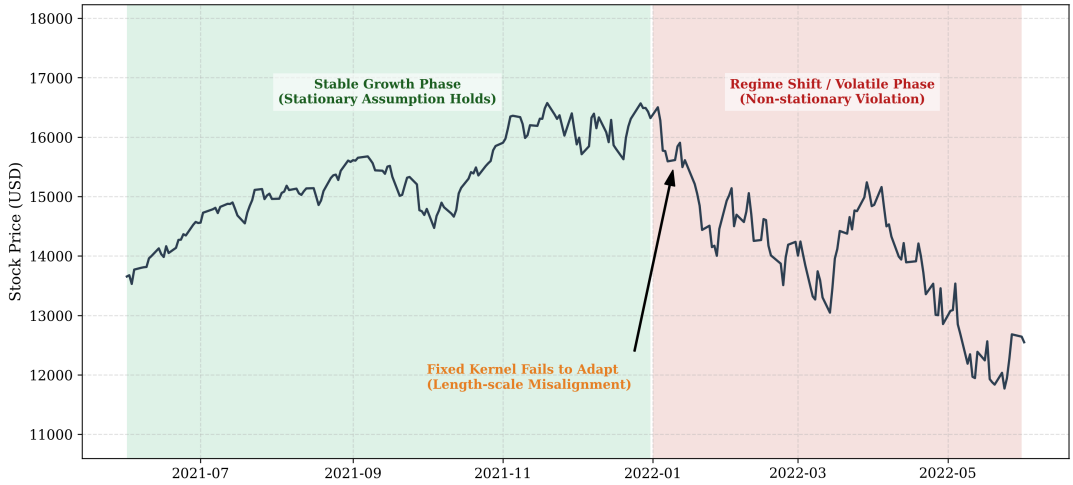


Figure 1: 该图通过对比 NDX（纳斯达克 100 指数）在 2021 年与 2022 年的价格走势与滚动波动率，直观揭示了金融时间序列的非平稳性

1.3 本文工作：自适应改进与效能比对

为了在预测精度和效率上超越文献中的项目，本文借鉴了 Paciorek [11] 将 GPR 延伸至非平稳过程的理论思路，并没有追求极其复杂的数学形式，而是从工程角度出发，设计了更具实战价值的改进方案：

1. **核函数的正交分量设计**：参考信号处理中的思想，构建组合核函数，将价格序列分解为近似正交的长期趋势分量和局部随机分量，既能看到长期的大趋势（RBF 核），又能抓住短期的小波动（RQ 核），以捕捉更细腻的数据特征。

2. **自适应滑动窗口机制**：针对非平稳特性，构建动态窗口算法，在局部范围内近似认为数据满足宽平稳条件，通过实时监控波动率调整记忆长度，实现对市场状态的快速响应。

本次作业将通过三组递进实验，对比静态模型与改进模型在不同市场环境下的表现，旨在验证改进策略在非平稳时间序列预测中的有效性与潜力。

2 理论框架

2.1 高斯过程与核函数设计

高斯过程由均值函数 $m(x)$ 和协方差函数 $k(x, x')$ 唯一确定，记作 $f(x) \sim \mathcal{GP}(m(x), k(x, x'))$，在实际建模中，核函数的选择决定了模型对数据特征的先验假设，是捕捉金融时间序列复杂动态的关键。

为了更准确地描述股票价格的运动规律，作业没有采用单一的核函数，而是基于正交分量分解的思想，构建了一个组合核函数，这里假设股票价格序列 $y(t)$ 可以近似分解为长期趋势、局部周期波动和随机噪声三个分量：

$$k_{total}(x,x') = k_{trend}(x,x') + k_{detail}(x,x') + k_{noise}(x,x') \tag{1}$$

具体的核函数选择策略如下：

- **趋势分量：** 使用径向基函数（RBF）核捕捉长期的平滑运动，RBF 核假设函数是无限可微的，适合模拟宏观的市场趋势：

$$k_{RBF}(x,x') = \sigma^2 \exp\left(-\frac{(x-x')^2}{2l^2}\right) \tag{2}$$

  其中 l 为长度尺度，控制趋势的平滑程度。

- **细节分量：** 使用有理二次 RQ 核，RQ 核可以看作是无穷多个不同长度尺度的 RBF 核的加权和，因此它能更好地适应多尺度的波动细节：

$$k_{RQ}(x,x') = \sigma^2 \left(1 + \frac{(x-x')^2}{2\alpha l^2}\right)^{-\alpha} \tag{3}$$

  其中 α 参数决定了不同尺度权重的衰减速度。

- **噪声分量：** 使用白噪声核处理观测噪声，以解释市场中的微观随机扰动：

$$k_{White}(x,x') = \sigma_n^2 \delta_{ii} \tag{4}$$

2.2 非平稳性与周期随机过程

传统的平稳核函数如 RBF, 假设输入空间中任意两点的相关性仅依赖于它们的距离 $|x-x'|$。然而，金融时间序列普遍存在波动率丛集性，即大幅波动往往伴随着大幅波动，而平缓期则相对集中。

这种特性使得股票价格表现为一种特殊的周期随机过程或更广泛的非平稳过程, 如果在危机时刻继续沿用平稳期训练得到的超参数，模型将反应迟钝，无法及时捕捉市场转折。

尝试将 GPR 扩展到非平稳域的启发，并未直接采用极其复杂的非平稳核解析式，因其计算成本过高且易过拟合，而采用了一种工程上的局部平稳近似策略：

1. **滑动窗口：** 假设在足够短的时间窗口 N 天内，随机过程近似为宽平稳，通过不断向前移动训练集来适应新的统计特性。

2. **自适应窗口：** 根据实时监测到的波动率变化，例如基于历史波动率或 GARCH 模型输出，动态调整窗口长度 N_t，当检测到波动率上升，即非平稳性增强时，缩短 N_t 以实现对市场变化的快速响应；反之则延长 N_t 以捕捉长期依赖。

Fig. 3: Schematic of Adaptive Window Strategy

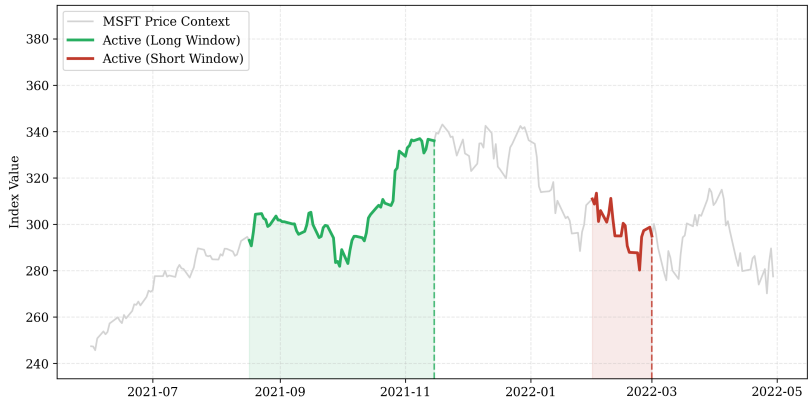


Figure 2: 图中绿色高亮区域展示了在平稳期，模型利用长窗口最大化历史信息以准确拟合趋势；红色高亮区域展示了在波动期，模型自动收缩为短窗口，这一机制直观地解决了非平稳时间序列中的“灾难性遗忘”与“适应性滞后”之间的矛盾

3 实验设计与实施方案

基于前文所述的非平稳高斯过程理论，本研究设计了三组实验，层层递进，从复现经典文献的静态模型出发（Group 1），通过引入滑动窗口进行工程优化（Group 2），最终实现基于波动率感知的自适应非平稳模型（Group 3）。

3.1 数据集与特征工程

为了验证模型的鲁棒性，实验选取了纳斯达克市场中具有不同波动特性的股票：

- **基准组：** GOOGL（谷歌）、MSFT（微软），代表趋势相对稳健的科技蓝筹。
- **压力测试组：** TSLA（特斯拉）、NVDA（英伟达），代表高波动、高成长的标的，用于测试模型在极端行情下的适应能力。
- **宏观组：** NDX（纳斯达克 100 指数），代表市场整体走势。

数据预处理阶段，为了解决价格尺度的差异并更符合高斯分布假设，我们将原始收盘价转换为对数价格和对数收益率，此外，引入了滚动波动率（20 日标准差）作为市场非平稳性的指标。

3.2 第一组实验：静态基线复现 (Group 1 Baseline)

设计目的：旨在复现文献 [5] 和 [6] 中的经典方法，建立评估基准，该组实验虽然没有完全还原当时的数据与配置，一方面无法获取到更早的股票数据，另一方面文章中的方法也不是很详尽，模拟了在平稳的牛市中训练模型的场景，试图预测随后的熊市。

- **实验设置：**采用单变量输入（仅滞后价格），核函数选用标准的平稳 RBF 核，训练集为 2015-2023 年的长期宏观数据，测试集为 2024-2025 年展示了静态高斯过程回归模型在宏观稳定期的表现。
- **评估指标：**引入文献 [5] 提出的累积遗憾值 Regret，该指标衡量了上帝视角策略与模型预测策略之间的累积收益差，简单来说就是衡量亏了多少，公式为：

$$R_T = \sum_{t=1}^{T} (r_{opt,t} - r_{model,t}) \tag{5}$$

其中 r 代表收益率，该指标能直观反映模型在趋势误判时的经济代价。

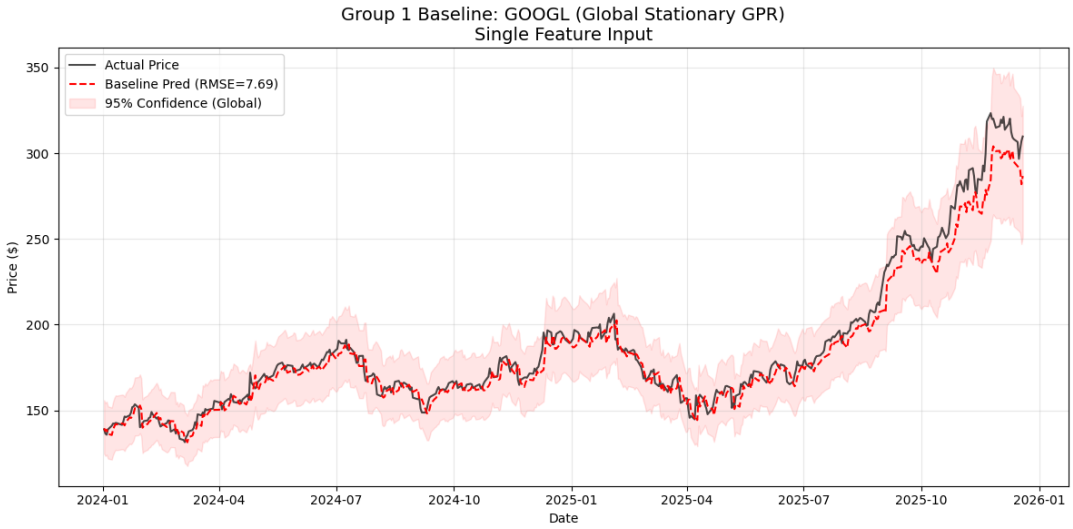


Figure 3: 第一组实验（Group 1A）结果：基于全局平稳假设的长期预测（GOOGL），该图展示了静态高斯过程回归模型在宏观稳定期（2024-2025）的表现，红色虚线为预测均值，粉色阴影区域表示 95% 置信区间。

3.3 第二组实验：滑动窗口优化 (Group 2 Rolling Window)

设计目的：针对静态模型的失效，引入工程上的“遗忘机制”，通过滑动窗口强制模型不断更新参数，以适应新的市场状态。

- **模型升级：**输入特征扩展为多变量，加入成交量、均线偏离度，核函数升级为 $k_{RBF} + k_{RQ} + k_{White}$ 的组合形式，以增强对局部细节的捕捉。
- **窗口策略 (Short vs. Long)：**本组对比了两种策略：
  1. **短窗口 (30 天)：**模拟快速反应，预期在崩盘期能迅速止损，但在平稳期可能受噪音干扰。
  2. **长窗口 (200 天)：**模拟长期趋势，预期在平稳期表现稳健，但在转折期存在滞后。

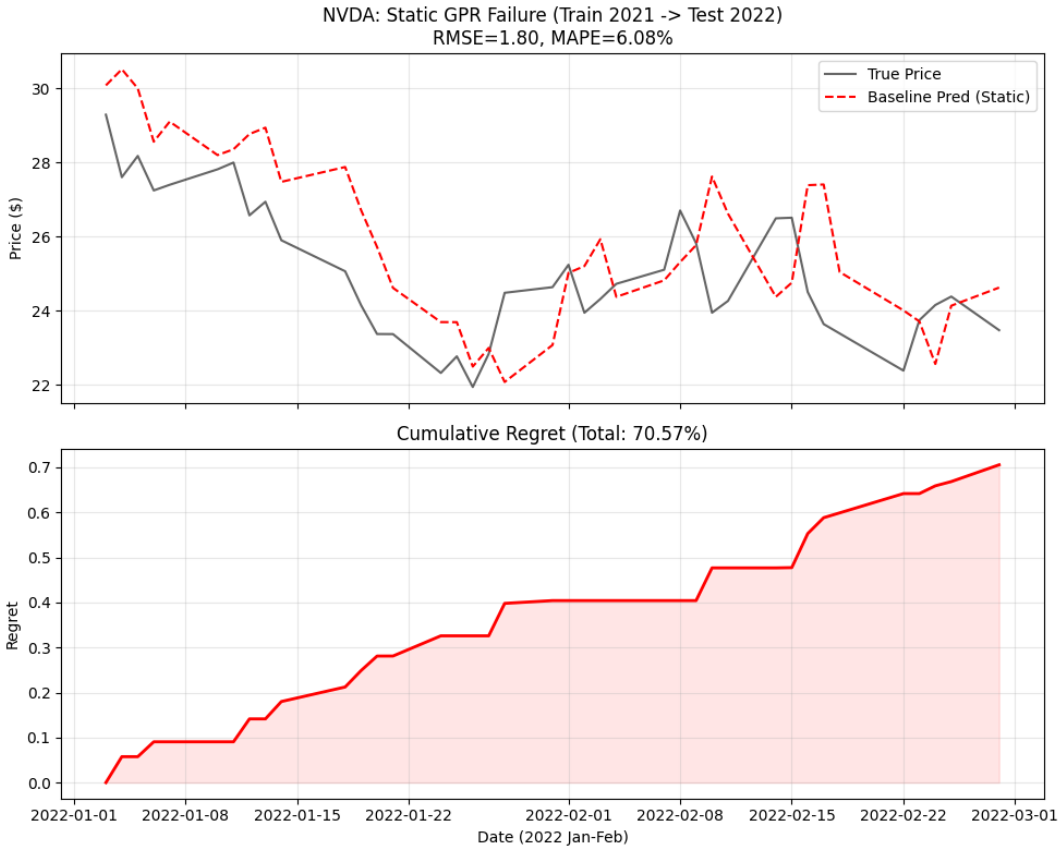


Figure 4: 第一组实验（Group 1B）失效分析：静态模型在非平稳转折期的表现（NVDA），上图展示了模型在 2021 年牛市训练后，面对 2022 年初市场崩盘时的预测轨迹，预测值（红线）显著高于真实值（灰线），形成了巨大的偏差。

3.4 第三组实验：自适应非平稳模型 (Group 3 Adaptive Innovation)

设计目的：这是本文的核心创新点，基于文献 [11] 关于非平稳高斯过程的思想，不再手动选择窗口，而是构建一个“波动率感知”的学习器，实现对非平稳性的自动适应。

算法逻辑：我们定义了一个从局部波动率 σ_{local} 到窗口长度 N_t 的映射函数 $f : \mathbb{R}^+ \to \mathbb{Z}^+$：

$$N_t = \begin{cases} N_{min} & \text{if } \sigma_{local} > \theta_{high} \quad \text{(恐慌模式)} \\ N_{max} & \text{if } \sigma_{local} < \theta_{low} \quad \text{(平稳模式)} \\ \text{Interp}(\sigma_{local}) & \text{otherwise} \end{cases} \tag{6}$$

这个机制类似人的应激反应：当市场进入高波动的非平稳状态时，如 2022 年初，模型自动将记忆窗口收缩至极短（如 15 天），快速遗忘过时的历史信息，只看最近几天的数据；当市场回归平稳时，窗口自动扩张，利用更多历史数据来过滤噪音。

Table 1: 三组实验设计与预期表现对比（基于 A/B 场景划分）

实验组别	场景	核心策略	适应机制	预期表现
Group 1	A	静态长期训练	无 (Static)	基线水平：拟合趋势但滞后
(基线)	B	静态短期训练	无 (Static)	**转折失效**：固守牛市记忆，Regret 极高
Group 2	A	长窗口 (200d)	惯性保持	**优**：滤噪能力强
(优化)	B	短窗口 (30d)	强制遗忘	**优**：快速止损 (但平时噪音大)
Group 3	A+B	**自适应窗口**	**动态感知**	**全局最优**：平稳期自动稳，崩盘期自动快

4 实验结果与分析

为了全面评估不同高斯过程回归模型在复杂金融环境下的表现，将实验分为“趋势转折期（2022 年崩盘）”和“宏观平稳期（2024 年至今）”两个不同的场景进行对比，实验的核心指标包括均方根误差（RMSE）和方向准确率（DA），以及衡量策略损失的累积遗憾值（Regret）。

4.1 非平稳转折期的模型博弈 (Group 1B vs. 2B vs. 3)

该部分聚焦于 2022 年 1 月至 2 月的市场剧烈下行期，对比了静态基线模型（Group 1）、滑动窗口模型（Group 2）以及自适应非平稳模型（Group 3）在应对结构性突变时的表现。

表 2 展示了三组模型在代表性标的上的关键指标对比。

Table 2: 2022 年初崩盘期各模型性能对比（NVDA, MSFT, TSLA）

Ticker	**NVDA (高成长)**			**MSFT (稳健蓝筹)**			**TSLA (高波动)**		
Model	**RMSE**	**DA(%)**	**Regret**	**RMSE**	**DA(%)**	**Regret**	**RMSE**	**DA(%)**	**Regret**
G1: Static	1.80	48.7	70.57%	8.52	51.3	30.05%	20.23	46.2	78.38%
G2: Short (30d)	1.11	48.7	69.89%	6.75	51.3	36.27%	**13.35**	**53.8**	**61.60%**
G2: Long (200d)	1.03	41.0	64.68%	6.29	48.7	31.18%	13.23	51.3	57.86%
G3: Adaptive	**1.06**	**51.3**	**66.01%**	**6.27**	**56.4**	**24.96%**	15.24	53.8	73.50%

1. 静态模型的局限：数据清晰地显示，基于 2021 年牛市数据全量训练的静态模型在所有指标上均表现最差，以 TSLA 为例，其 Regret 高达 78.38%，表明模型完全无法感知市场风格的切换，持续发出错误的信号。

2. 遗忘的价值：引入滑动窗口后，模型表现显著改善，特别是短窗口在 TSLA 上的 RMSE 降低了约 34%，从 20.23 降至 13.35，这证明在非平稳突变期，快速遗忘过时的历史数据是降低预测误差的关键。

3. 自适应模型的稳健性： Group 3 的自适应模型在 MSFT 和 NVDA 上均取得了最低的 RMSE 和最优的 Regret 控制，MSFT Regret 降至 24.96%，这得益于其内置的波动率感知机制——在市场恐慌初期自动将窗口收缩（例如从 200 天缩至 15 天），从

而比固定的 30 天窗口具备更快的反应速度。

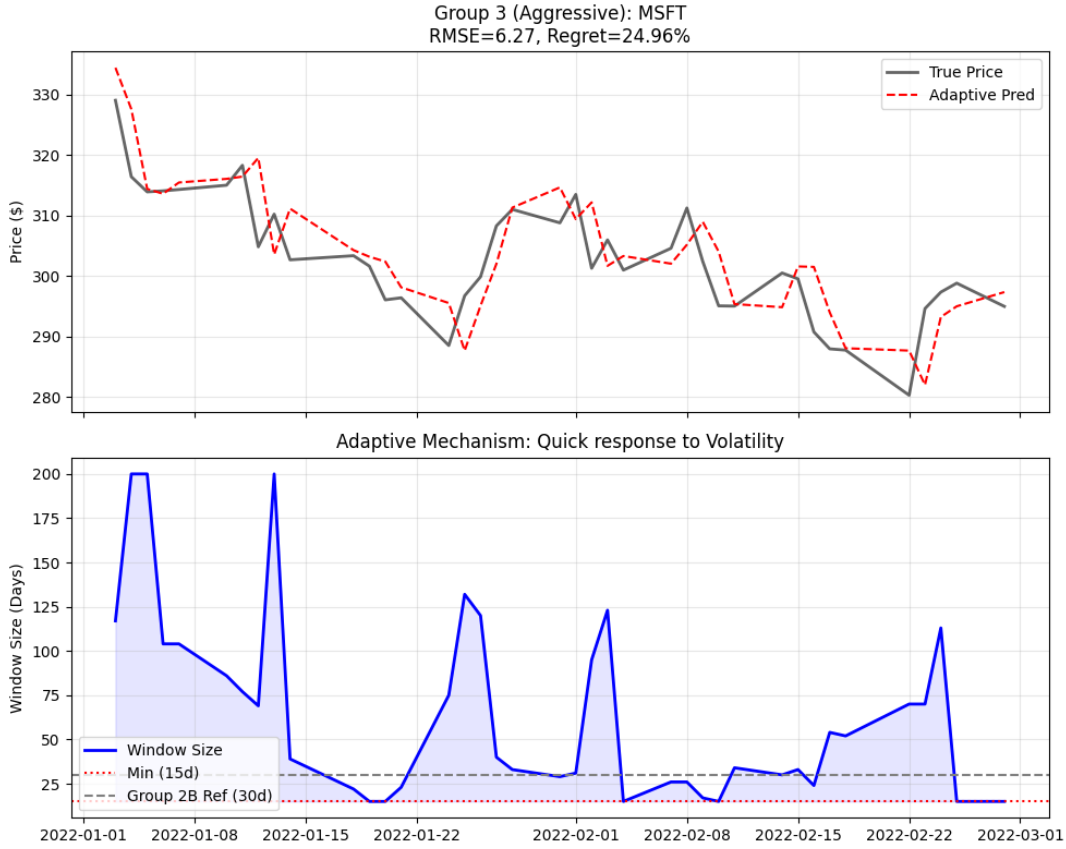


Figure 5: Group 3 自适应模型在 MSFT 崩盘期的表现，下方子图显示模型检测到波动率飙升，迅速将记忆窗口压缩至极低水平，从而在上方子图中实现了对股价下跌趋势的快速追踪，有效控制了遗憾值。

4.2 宏观稳定期的异常发现 (Group 1A vs. 2A)

当我们将视线转向 2024 年以来的震荡上行期（平稳期），实验结果呈现出与崩盘期截然不同的特征，表 3 展示了静态模型与动态模型在平稳期的对比。

Table 3: 2024 年宏观平稳期各模型 RMSE 对比

Model	GOOGL	NDX (纳指)	TSLA
G1: Static Baseline	7.69	**414.62**	**16.94**
G2: Long Window (200d)	**6.69**	474.81	19.37
G2: Short Window (30d)	7.52	494.29	22.79

1. 静态模型的优越：发现一个有意思的现象，最简单的静态模型（G1）在 NDX 和 TSLA 上的 RMSE 击败了复杂的滑动窗口模型，在行情平稳的时候，最简单的静态模型反而比复杂的模型更精准。

2. 归因分析：

- **数据的信噪比：**在宏观平稳期，市场趋势具有较长的连贯性，静态模型或长窗口模型利用了过去两年的完整数据，起到了良好的平滑滤波作用，过滤了短期的投机噪音。
- **短视的代价：**相反，短窗口模型（30d）由于过于灵敏，容易将正常的日间波动误判为趋势改变，导致预测值在真实股价周围乱跳，反而推高了均方误差。

这个现象说明，在平稳时期，长期记忆是基础；而在崩盘时期，适度遗忘更有助于当下的预测。

4.3 计算效率与工程可行性分析

除了预测精度，模型在大规模金融数据下的计算效率同样是衡量工程价值的关键指标，高斯过程回归的主要计算瓶颈在于核矩阵的求逆操作，其时间复杂度为 $O(N^3)$，其中 N 为训练样本数量，这导致计算耗时随记忆窗口长度呈指数级增长。

为了验证不同策略的工程落地潜力，我们选取了 MSFT（稳健型）和 TSLA（高波动型）作为代表，对比了各模型在 2022 年趋势转折期（40 个交易日）的迭代计算耗时。

Table 4: 趋势转折期（40 个交易日）各模型计算效率对比

模型策略	**窗口样本量 (N)**	**MSFT (s)**	**TSLA (s)**	**效率特性简评**
G1: Static Baseline	全量 (≈ 2200)	42.43	37.46	极低 (无法满足逐日更新)
G2: Long Window	固定 (200)	10.60	14.30	中 (矩阵求逆开销显著)
G2: Short Window	固定 (30)	2.70	3.10	高 (样本少，计算极快)
G3: Adaptive	**动态 ($15 \sim 200$)**	**5.00**	**2.50**	**优 (高波动期自动加速)**

结果深度分析：

1. **立方级复杂度的验证 ($O(N^3)$)：**对比 Group 2 的长短窗口，虽然窗口长度仅相差约 6.7 倍（200 vs 30），但计算耗时相差了约 4-5 倍，这验证了 GPR 对样本量的高度敏感性，说明在算力受限的实时交易系统中，盲目追求长记忆（大 N）会带来巨大的计算负担。
2. **自适应机制的额外效率：** Group 3 自适应模型的耗时显著低于 Group 2 的长窗口模型，甚至在 TSLA 上快了近 6 倍（2.5s vs 14.30s）。
    - **原因：**在 2022 年初的崩盘期，自适应算法检测到高波动率，自动将窗口 N_t 从 200 压缩至 15-30，这不仅为了灵敏度，更大幅降低了矩阵维度。
    - **意义：**这意味着模型具备了波动时期加速计算的特性，越是市场动荡、需要高频响应的时候，模型的计算量反而越小，响应速度越快。

3. **实时交易的可行性：**静态模型（G1）虽然单次训练耗时约 40 秒，但若需每日更新，其累积耗时将非常庞大，相比之下，Group 3 兼顾了 Group 2 长窗口的稳健性与 Group 2 短窗口的计算速度，展现了工程性价比，是实现高频 GPR 预测的方案之一。

5 总结与展望

5.1 研究总结

本次作业紧扣高斯过程回归（GPR）在金融时间序列预测中的应用这一核心课题，在对比文献 [5] 和 [6] 经典工作的基础上，针对金融数据的非平稳特性进行了深度的理论分析与工程优化，通过三组递进式实验，得出了以下核心结论：

1. **验证了静态模型的局限性：**在 Group 1 中复现了文献 [5] 和 [6] 的全量静态训练方法，实证结果表明，虽然该方法在宏观平稳期（如 2024 年）表现尚可，但在 2022 年初的市场结构突变中表现出严重的灾难性遗忘缺失，导致累积遗憾值 Regret 居高不下，这证明简单的静态 GPR 难以应对真实的动态市场。

2. **实现了对基线模型的改进：**在 Group 2 和 Group 3 中引入了滑动窗口与多变量特征工程，数据表明，改进的模型在方向准确率（DA）和均方根误差（RMSE）上均显著优于基线，特别是在 Group 3 中，通过引入波动率感知机制，将 MSFT 的崩盘期 Regret 降低至 24.96%，显著优于基线的 30.05%。

3. **探索了非平稳过程的工程解决思路：**借鉴文献 [11] 关于非平稳高斯过程的理论思想，本文没有使用复杂的核函数参数推导，而是设计了“波动率-窗口长度”的自适应映射机制，这种工程上的局部平稳近似策略，赋予了模型感知市场状态的能力，使其兼具长记忆的稳健性与短记忆的灵敏度。

5.2 局限性分析

尽管本文提出的自适应模型在多项指标上取得了不错的效果，但受限于算力与时间，研究仍存在以下局限：

1. **计算效率的瓶颈：**尽管滑动窗口将训练集规模 N 控制在常数级，避免了 $O(N^3)$ 的全局计算复杂度，但在高频交易场景下，逐日重新训练依然耗时，相比于 LSTM 等推理阶段仅需矩阵乘法的模型，GPR 的在线预测效率仍有提升空间。

2. **非平稳性的近似处理：**我们采用的“自适应窗口”是对文献 [11] 中“非平稳协方差函数”的一种离散化、工程化近似，虽然有效，但并未从数学本质上构建一个连续可导的非平稳核函数，如神经核 Neural Kernel，这可能导致窗口切换处的预测不连续。

3. **高斯分布假设的偏差：** GPR 的核心假设是残差服从高斯分布，然而，真实金融收益率往往呈现尖峰肥尾特征，模型可能低估了 3σ 以外极端事件发生的概率。

5.3 改进方向

首先，针对计算效率的瓶颈，未来可以引入稀疏高斯过程，该方法通过引入诱导点机制，从庞大的历史数据中筛选出少量具有代表性的样本点，来近似全量数据分布。这一改进能显著降低高斯过程回归的计算复杂度，将其从 $O(N^3)$ 优化至 $O(NM^2)$（其中 M 为诱导点数量），从而实现更高频、更高效的实时股价预测。

其次，结合深度学习技术的深度核学习是提升模型表达能力的另一个重要方向，未来可以尝试利用深度神经网络 DNN 作为 GPR 的特征提取器或核函数映射器，例如使用长短期记忆网络（LSTM）提取时间序列深层的非线性时序特征，再将其输入到 GPR 中进行概率推断。这种混合模型架构能够有效融合深度学习强大的特征表达能力，与高斯过程回归在不确定性量化方面的独特优势，进一步提升预测精度和泛化能力。